

Contexte et enjeux

Les LLM modernes souffrent de deux limites complémentaires : d'un côté, la **RAG** (Retrieval-Augmented Generation) améliore la fidélité factuelle en injectant du savoir externe, mais elle échoue souvent dans les tâches nécessitant un raisonnement multi-étapes complexe 【1†L13-L22】. De l'autre, les approches basées sur le raisonnement (CoT, chaînes logiques, etc.) peuvent exceller dans l'inférence, mais elles **hallucinent** fréquemment ou produisent des faits erronés. Li *et al.* (2025) proposent de rompre cette dichotomie en unifiant **recherche d'information** et **raisonnement profond** dans des systèmes « RAG-Reasoning » 【1†L13-L22】. Leur enquête identifie trois grands paradigmes évolutifs au carrefour de ces deux domaines 【21†L948-L956】 : le RAG optimisé par le raisonnement, le raisonnement ancré par la RAG, et une architecture synergique de type agentique où recherche et raisonnement co-évoluent en boucles itératives 【21†L948-L956】.

Les trois paradigmes RAG-Raisonnement

1. RAG optimisé par le raisonnement (Reasoning-Enhanced RAG)

Dans ce paradigme, on enrichit le **pipeline classique** de RAG (retrieval puis génération) par des mécanismes de raisonnement à chaque étape 【5†L226-L234】. L'idée est d'**optimiser la recherche d'informations** en reformulant intelligemment la requête (p. ex. via Chain-of-Thought pour décomposer la question), ou en planifiant globalement quelles sources interroger. Lors de l'**intégration des résultats**, le modèle applique des filtres critiques pour supprimer les contenus hors sujet ou contradictoires (via évaluation de pertinence). Enfin, la **génération** finale est guidée pour rester cohérente et factuelle (par exemple en ancrant le discours sur des preuves récupérées et en évitant les digressions). Au global, ce couplage raisonnement–RAG permet de « chercher plus pertinent » et de réduire les hallucinations dans la réponse 【5†L226-L234】.

2. Raisonnement ancré par la RAG (RAG-Enhanced Reasoning)

Ici on part de chaînes de raisonnement complexes et on leur apporte un **socle factuel** par la récupération de connaissances. Les modèles extraient dynamiquement des faits externes — issues de bases de données spécialisées, de pages web ou de bibliothèques de codes — pour combler les prémisses manquantes et étayer leurs inférences 【11†L430-L439】. Par exemple, on interroge des ontologies logiques ou des corpus scientifiques (AlignRAG, MultiHop-RAG) pour renforcer les étapes de raisonnement déductif, ou l'on fait appel à des outils (calculatrices, API financières, bibliothèques de fonctions) pour valider des calculs intermédiaires 【11†L430-L439】. Dans le même esprit, l'**in-context retrieval** fournit des exemples pertinents tirés du passé du modèle (conversations antérieures ou démonstrations annotées) pour guider le raisonnement lors de tâches nouvelles 【13†L509-L517】. Cette démarche « ancrée » diminue les fausses inférences en fournissant un contexte factuel étendu.

3. Synergie RAG–Raisonnement (l'ère agentique)

Ces systèmes de pointe intercalent de façon itérative recherche d'information et raisonnement dans une boucle continue. Plutôt que l'enchaînement linéaire « rechercher puis raisonner » des pipelines traditionnels, l'**agent** planifie un chemin de recherche, puise des données, évalue ses conclusions, identifie de nouvelles lacunes puis relance une recherche, et ainsi de suite [21+L954-L956]. La Figure ci-dessous, tirée de la littérature récente, illustre cette transition vers des agents de "Deep Research" autonomes [21+L954-L956] [40+L88-L92] :

【38+embed_image】 *Figure – Évolution des paradigmes de recherche d'information : du moteur Web classique aux LLM agents (« Deep Research ») combinant recherche et raisonnement [21+L954-L956] [40+L88-L92] .*

Dans ces systèmes, des **flux de raisonnement structurés** sont employés :

- **Chain-based (linéaire)** : le raisonnement est décomposé en séquences d'étapes successives (CoT). Des approches comme IRCoT ou Rat alternent recherche et inférence pas à pas [23+L573-L582], voire vérifient rétroactivement chaque étape sur des références récupérées (CoV-RAG) pour corriger automatiquement les erreurs [23+L579-L588]. Des prompts style ReAct ou Self-Ask ordonnent au modèle de générer et résoudre sous-question par sous-question, conduisant à un raisonnement incrémental.
- **Tree-based (arborescent)** : on explore simultanément plusieurs branches de raisonnement. Par exemple, les modèles construisent un arbre de pensées (Tree-of-Thought) où chaque nœud correspond à une hypothèse alternative. Des travaux comme RATT évaluent plusieurs trajectoires logiques en parallèle [23+L591-L600]. D'autres recourent à Monte-Carlo Tree Search (AirRAG, MCTS-RAG) pour guider l'expansion des branches les plus prometteuses en évaluant dynamiquement leur score d'utilité [23+L591-L600]. Cela évite qu'une erreur initiale ne « verrouille » tout le raisonnement.
- **Graph-based (KG-bootstrapping)** : le modèle interagit avec un graphe de connaissances. Dans le schéma *Walk-on-Graph*, on enrichit la recherche par des réseaux de neurones graphes (PullNet, QA-GNN) qui agrègent l'information de nœuds voisins [23+L614-L623]. Dans le mode *Think-on-Graph*, l'agent lui-même décide quel nœud ou relation explorer à chaque étape dans un graphe construit sur le vol, naviguant ainsi entre entités sémantiques pour aboutir à la réponse [23+L629-L637].

Parallèlement, on distingue deux formes d'**orchestration agentique** [15+L653-L657] [16+L721-L729] :

- **Mono-agent** : un seul LLM pilote l'ensemble, insérant dynamiquement des appels de recherche à chaque étape de son raisonnement [15+L653-L657]. C'est le cas des frameworks comme ReAct (l'agent interroge la base de données en alternance avec la réflexion) ou DeepRAG (auto-vérification et recherche itérative). Ces modèles peuvent être entraînés via fine-tuning (ex. Toolformer, INTERS) ou prompts avancés pour apprendre à « quand chercher, comment intégrer, quand arrêter ».

- **Multi-agents** : plusieurs agents spécialisés collaborent (domaine du *multi-agent reasoning*). Dans les architectures décentralisées, chaque agent interroge une source ou effectue un type de raisonnement particulier, puis partage ses trouvailles (Collab-RAG, MDocAgent pour documents multimodaux) 【16†L721-L729】. Dans les architectures centralisées, on hiérarchise les rôles (par exemple un « planificateur », plusieurs « chercheurs », un « décideur »), afin de diviser et coordonner le travail sur des tâches complexes (HM-RAG, SurgRAW) 【16†L721-L729】.

Défis ouverts et perspectives

Li *et al.* soulignent plusieurs verrous techniques à surmonter pour industrialiser ces systèmes agentiques. Tout d’abord, les **interférences factuelles** restent critiques : si les documents récupérés contiennent des erreurs ou des contradictions, ils peuvent « dérailler » les chaînes de raisonnement interne 【1†L69-L76】. Par exemple, un fait faux introduit tôt dans le raisonnement risque d’invalider toute la suite. Ensuite, le **coût informatique** est élevé : chaque boucle de recherche implique de multiples requêtes et étapes de raisonnement, amplifiant la latence (une seule requête « deep research » peut prendre de l’ordre de dix minutes) 【28†L796-L804】 , et la consommation de jetons explose. Enfin, l’**évaluation** pose problème : les jeux de données classiques (QA statique) ne mesurent pas l’efficacité des trajectoires dynamiques d’un agent (itinéraire de recherche, cohérence logique au fil des étapes). Les auteurs notent le manque de benchmarks standardisés pour juger tout le pipeline retrieval–raisonnement (temps de recherche, pertinence intermédiaire, consistance du raisonnement) 【34†L2643-L2646】. D’autres défis incluent la fiabilité vis-à-vis de sources malicieuses (atténuer les attaques adversariales via watermarking, suivi de provenances 【31†L928-L936】), l’efficacité (optimiser la profondeur de raisonnement sans itérer à l’infini 【28†L796-L804】), ou l’inclusion de contenus multimodaux (images, documents tables) dans les boucles d’extraction.

Jeux de données et ressources associées

Le survey répertorie une cinquantaine de benchmarks couvrant de 13 tâches (QA multi-sauts, logiques, mathématiques, code, fact-checking, etc.) et 12 domaines 【33†L2151-L2159】. Par exemple, **HotpotQA** oblige à fusionner des informations issues de plusieurs articles Wikipedia 【33†L2151-L2155】 , des évaluations de programmation (LiveCodeBench) demandent de chercher dans la documentation du code, et même des examens comme *Humanity’s Last Exam* (HLE) requièrent un haut niveau d’expertise combinant recherche web et logique 【33†L2167-L2174】. Ces ensembles soulignent l’importance de « vraie » multi-étape : on doit non seulement extraire l’information pertinente, mais l’intégrer de façon cohérente. En pratique, les auteurs ont compilé ces ressources sur GitHub : le dépôt *Awesome-RAG-Reasoning* recense les derniers papiers, datasets spécialisés (HotpotQA, HLE, etc.) et implementations open-source liées à ces paradigmes 【1†L29-L34】.

【21†L948-L956】 【5†L226-L234】 【11†L430-L439】 【23†L579-L588】 【28†L796-L804】 【34†L2643-L2646】 Sources : Li *et al.*, “Towards Agentic RAG with Deep Reasoning”

(ArXiv, 2025) pour l'ensemble des concepts présentés. L'évolution vers des agents de recherche autonomes, illustrée ci-dessus, est également discutée dans Zhang et al. (2025) **[21†L954-L956]** **[40†L88-L92]** .
